Thao tác với tệp dữ liệu sử dụng Pandas

Giảng viên: TS. Nguyễn Văn Quyết

Email: quyetict@gmail.com

Nội dung

- Khái quát về đọc và ghi dữ liệu trên Pandas
- Đọc và ghi dữ liệu tệp CSV
- Đọc và ghi dữ liệu tệp JSON
- Đọc và ghi dữ liệu tệp XML

1. Khái quát về đọc và ghi dữ liệu với tệp trên Pandas

- Pandas cung cấp các hàm đọc và ghi dữ liệu từ các đối tượng pandas.
- Hàm đọc dữ liệu từ tệp có dạng read_loaitep() trả về một DataFrame:
 - Ví dụ: Hàm read_excel() đọc dữ liệu từ tệp .xlsx và trả về một dataframe.
- Hàm ghi dữ liệu từ tệp có dạng DataFrame.to_loaitep() sẽ ghi một DataFrame dưới dạng định dạng tệp.
 - Ví dụ: Hàm DataFrame.to excel() sẽ ghi dữ liệu từ DataFrame thành một file .xlsx.

Khái niệm về tệp csv

- CSV, viết tắt của comma-separated values, là một loại tệp text sử dụng dấy phẩy "," để chia cắt giữa các giá trị.
- Mỗi dòng của tệp là một bản ghi (record) của dữ liệu.
- Mỗi bản ghi có thể gồm nhiều trường, với dấu phẩy "," được dùng để chia cắt các trường.
- Tệp csv được dùng để ghi dữ liệu dạng bảng dưới dạng text.

```
E COVID-19 Dataset.csv
      Continent, Country, Last_Updated_Date, Total_Cases, Total_Deaths, Total_Cases_Per_Million, Total_Deaths_Pe
      Asia, Afghanistan, 11-10-2021, 155540, 7228, 3904.565, 181.447,,,2369625, 828601,,39835428, 54.422, 18.6, 2.58
      Europe, Albania, 11-10-2021, 175163, 2777, 60970.074, 966.608, ,, 1795351, 962281, 833070, 2872934, 104.871, 38, 1
      Africa, Algeria, 11-10-2021, 204695, 5855, 4587.864, 131.229, , , , , , 44616626, 17.348, 29.1, 6.211, 3.857, 13913.8
      Europe, Andorra, 11-10-2021, 15307, 130, 197882.462, 1680.585, 215733, 0.054, ,,, 77354, 163.755, ,,,
      Africa, Angola, 11-10-2021, 61580, 1629, 1814.72, 48.006, ,, 4074677, 2863708, 1210969, 33933611, 23.89, 16.8, 2.4
      North America, Anguilla, 01-10-2021,,,,,,,18704,9548,9156,15125,,,,,
      North America, Antigua and Barbuda, 11-10-2021, 3750, 93, 37983.146, 941.982, ,, 98840, 54435, 44405, 98728, 231
      South America, Argentina, 11-10-2021, 5266275, 115491, 115473.741, 2532.374, 24156096, 0.019, 54115894, 302652
      Asia, Armenia, 11-10-2021, 272957, 5575, 91962.678, 1878.288, 1770914, 0.102, 514241, 344029, 170212, 2968128, 16
      North America, Aruba, 10-10-2021,,,,,,,157541,81871,75670,107195,584.8,41.2,13.085,7.452,35973.781
      Oceania, Australia, 11-10-2021, 131415, 1461, 5095.932, 56.654, 39943525, 0.012, 31020482, 17808025, 13212457, 2
      Europe, Austria, 11-10-2021, 762538, 11106, 84322.894, 1228.122, 90377770, 0.005, 10957619, 5790455, 5483648, 96
      Asia, Azerbaijan, 11-10-2021, 492790, 6677, 48202. 428, 653. 113, 4952737, 0.087, 8997289, 4889404, 4107885, 10223
      North America, Bahamas, 11-10-2021, 21580, 590, 54369.46, 1486.468, 147633, 0.178, 224531, 129121, 100098, 39691
      Asia, Bahrain, 11-10-2021, 275734, 1390, 157715.946, 795.06, 6612314, 0.004, 2669575, 1168806, 1129802, 1748295,
      Asia, Bangladesh, 11-10-2021, 1562958, 27699, 9398.227, 166.557, 9907321, 0.035, 54798986, 36580037, 18218949, 1
      North America, Barbados, 11-10-2021, 11132, 98, 38692.007, 340.623, ,, 253554, 141820, 111734, 287708, 664.463, 3
```

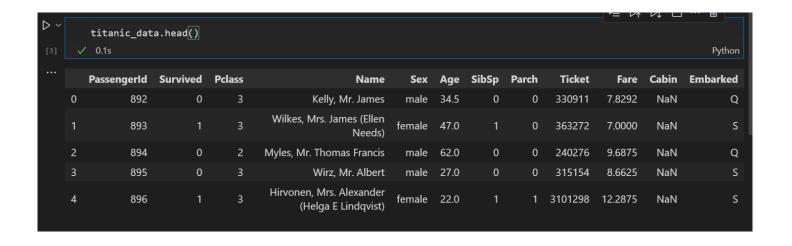
Khoa Công nghệ Thông tin - UTEHY

Đọc dữ liệu với tệp csv

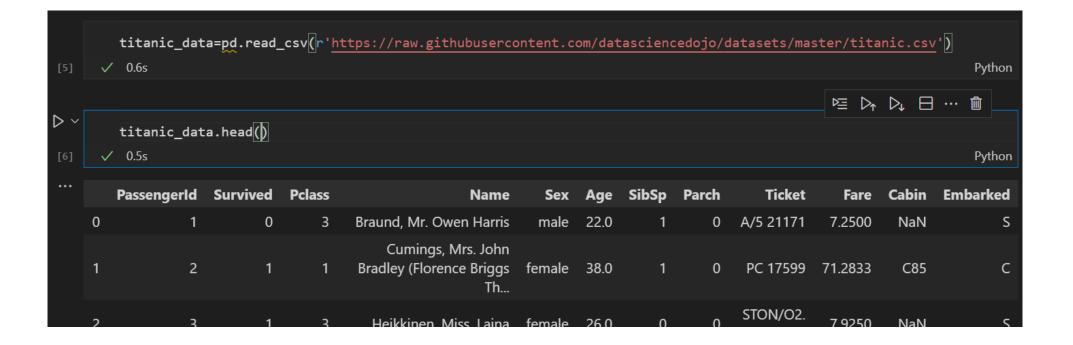
- Hàm read_csv() được dùng để đọc dữ liệu từ tệp csv, hàm trả về một đối tượng DataFrame.
- Các tham số cơ bản của hàm read_csv():
 - filepath_or_buffer: đường dẫn tới file cần đọc.
 - sep: phần tử chia cắt các giá trị giữa các trường, mặc định ",".
 - header: số dòng được chọn làm header.
 - dtype: sử dụng để định nghĩa kiểu dữ liệu cho toàn bảng hoặc từng cột.

- Tải file theo đường link sau: Titanic dataset | Kaggle
- Đổi tên file thành titanic.csv
- Đọc dữ liệu từ file dùng pandas:

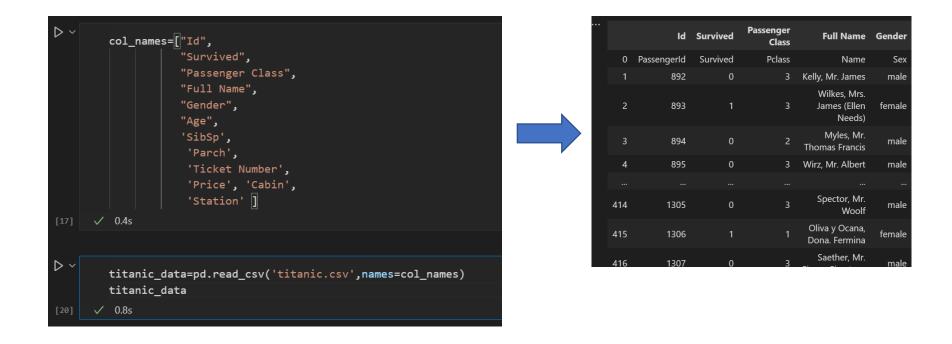
- Xem qua dữ liệu của DataFrame bằng hàm head()
 - Hàm head() sẽ hiển thị 5 bản ghi đầu tiên của DataFrame.



- Có thể sử dụng đường link trực tuyến đến file thay vì tải trực tiếp về máy:
 - Sử dụng đường link sau để đọc dữ liệu thay vì tải trực tiếp về máy:
 https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv



Theo mặc định, hàng đầu tiên của file sẽ được lấy làm tên của cột. Tuy nhiên trong nhiều trường hợp, tên cột mặc định trong file có thể không phù hợp. Ta có thể điều chỉnh tên cột bằng cách điều chỉnh thuộc tính names:



Ta thấy rằng sau khi thêm header thì dòng đầu tiên của file sẽ trở thành một bản ghi trong DataFrame. Để loại bỏ dòng này, ta sử dụng tham số skiprows.



Người dùng có thể loại bỏ header bằng cách đặt header=None và skiprows=[0]



Ví dụ 2: Ghi dữ liệu tệp DataFrame ra tệp csv

Giả sử ta có DataFrame như sau:

Ví dụ 2: Ghi dữ liệu từ tệp DataFrame ra tệp csv

Để ghi dữ liệu vào tệp ta sử dụng hàm to_csv().

Hàm csv được tạo sẽ có dạng sẽ được mặc định có thêm cột index là địa chỉ các bản ghi.

```
1  ,full_name,class_id
2  0,Đặng Thành Nam,101191A
3  1,Lê Văn Long,101192
4
```

Loại bỏ cột Index khi tạo tệp

• Để loại bỏ cột index, ta cho tham số Index = False:



Điều chỉnh kí tự ngăn cách các giá trị

 Giá trị mặc định ngăn cách các giá trị là dấu "," ta có thể điều chỉnh thông qua tham số sep.



Xử lý dữ liệu khuyết thiếu

Dữ liệu khuyết thiếu trong pandas sẽ không được ghi ra tệp, tuy nhiên ta có thể thay thế dữ liệu khuyết thiếu bằng các giá trị mong muốn thông qua tham số na_rep.

```
students.to_csv("students.csv", index=False, na_rep="unknown")

1  full_name,class_id
2  Đặng Thành Nam,101191A
3  Lê Văn Long,101192
4  Nguyễn Hoài Nam,unknown
5
```

File JSON là gì?

- JSON, viết tắt của JavaScript Object Notation, là một kiểu dữ liệu mở trong JavaScript. Kiểu dữ liệu này bao gồm chủ yếu là text, có thể đọc được theo dạng cặp "thuộc tính - giá trị".
- JSON là một kiểu dữ liệu trung gian, chủ yếu được dùng để vận chuyển thông tin giữa các thành phần của một chương trình

```
"firstName": "John",
"lastName": "Smith",
"isAlive": true,
"age": 27,
"address": {
  "streetAddress": "21 2nd Street",
  "city": "New York",
  "state": "NY",
  "postalCode": "10021-3100"
"phoneNumbers": [
    "type": "home",
    "number": "212 555-1234"
    "type": "office",
    "number": "646 555-4567"
"children": [],
"spouse": null
```

Tạo JSON data với nested dictionary

- Oó thể sử dụng từ điển lồng (nested dictionary) để tạo dữ liệu JSON trong Python. Mỗi item ở vòng ngoài sẽ tương ứng với một cột trong JSON file.
- Mỗi từ khóa (key) tại mỗi cột là tên cột và mỗi giá trị tại từ điển bên trong sẽ là giá trị tại mỗi hàng tương ứng với cột.

```
In [15]: patients = {
                   "Name":{"0":"John","1":"Nick","2":"Ali","3":"Joseph"},
                  "Gender":{"0":"Male","1":"Male","2":"Female","3":"Male"},
                  "Nationality":{"0":"UK","1":"French","2":"USA","3":"Brazil"},
                   "Age" :{"0":10,"1":25,"2":35,"3":29}
                                                                                                             Name Gender Nationality Age
         patients
                                                                                                              John
                                                                                                                      Male
                                                                                                                                 UK
                                                                                                                                      10
Out[15]: {'Name': {'0': 'John', '1': 'Nick', '2': 'Ali', '3': 'Joseph'},
                                                                                                                              French
                                                                                                               Nick
           'Gender': {'0': 'Male', '1': 'Male', '2': 'Female', '3': 'Male'},
                                                                                                                                USA
                                                                                                                                      35
           'Nationality': {'0': 'UK', '1': 'French', '2': 'USA', '3': 'Brazil'},
                                                                                                                Ali Female
           'Age': {'0': 10, '1': 25, '2': 35, '3': 29}}
                                                                                                          3 Joseph
                                                                                                                               Brazil
                                                                                                                      Male
```

Tạo dữ liệu JSON với danh sách các từ điển (List of Dictionaries)

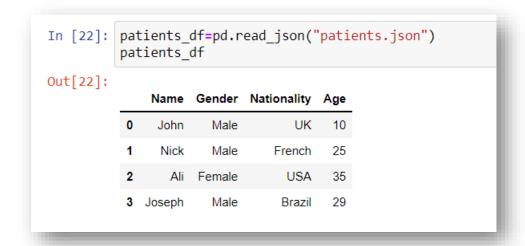
JSON có thể được tạo từ một danh sách bao gồm các từ điển có cùng số phần tử với nhau.

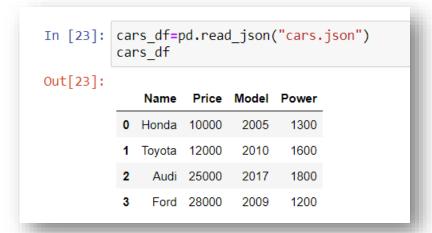
Ghi dữ liệu JSON tới file JSON trong Python

Với từ điển lồng và danh sách các từ điển, ta có thể lưu trữ dữ liệu vào file json thông qua thư viện json và hàm dump():

Đọc JSON file bằng Pandas

Ta sử dụng hàm read_json() để đọc dữ liệu từ file json và lấy về DataFrame tương ứng.





Ghi dữ liệu tới file JSON thông qua Pandas

Tương tự như với csv, DataFrame cũng có thể được lưu trữ dưới dạng file JSON thông qua hàm to_json().

```
In [26]: cars_df.to_json("cars1.json")

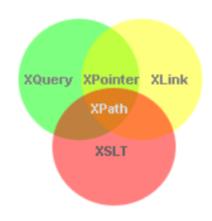
1 {"Name":{"0":"Honda","1":"Toyota","2":"Audi","3":"Ford"},"Price":{"0":10000,"1":12000,"2":25000,"3":28000},"Model": {"0":2005,"1":2010,"2":2017,"3":2009},"Power":{"0":1300,"1":1600,"2":1800,"3":1200}}
```

XML là gì?

- XML, viết tắt của Extensible Markup Language (ngôn ngữ đánh dấu có thể mở rộng), là ngôn ngữ đánh dấu với mục đích chung do W3C đề nghị, để tạo ra các ngôn ngữ đánh dấu khác.
- Mục đích chính của XML là đơn giản hóa việc chia sẻ dữ liệu giữa các hệ thống khác nhau, đặc biệt là các hệ thống được kết nối với Internet.
- XML cung cấp một phương tiện dùng văn bản (text) để mô tả thông tin và áp dụng một cấu trúc kiểu cây cho thông tin đó.

XPath là gì?

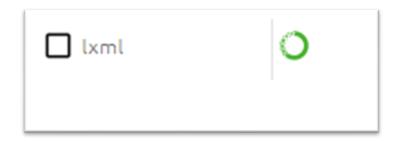
XPath là đường dẫn tới các element trong XML.



```
XPath Expression
/bookstore/book[1]
/bookstore/book[last()]
/bookstore/book[last()-1]
/bookstore/book[position()<3]
//title[@lang]
//title[@lang='en']
/bookstore/book[price>35.00]
/bookstore/book[price>35.00]/title
```

Đọc dữ liệu file XML với file

Tương tự như với csv và json, pandas có hàm read_xml để thiết kế để đọc dữ liệu từ file xml, người dùng cần tải package lxml, nếu không phải định nghĩa bộ chuyển đổi với tham số parser="etree" để giúp pandas có thể biết được bộ chuyển đổi nào sẽ sử dụng để chuyển đổi file xml sang cấu trúc mà pandas có thể hiểu được.



```
In [30]: df = pd.read_xml(xml, parser='etree')
    df
Out[30]:
```

Đọc dữ liệu từ xml

 Giả sử ta có cấu trúc xml như sau, hàm read_xml() được dùng để đọc dữ liệu từ xml sang DataFrame.

```
In [27]: xml = '''<?xml version='1.0' encoding='utf-8'?>
         <data xmlns="http://example.com">
            <shape>square</shape>
            <degrees>360</degrees>
            <sides>4.0</sides>
          </row>
          <row>
            <shape>circle</shape>
            <degrees>360</degrees>
            <sides/>
          </row>
          <row>
            <shape>triangle</shape>
            <degrees>180</degrees>
            <sides>3.0</sides>
          </row>
         </data>'''
In [31]: df = pd.read xml(xml)
Out[31]:
             shape degrees sides
                       360
                             4.0
            square
              circle
                       360
                            NaN
                       180
                            3.0
          2 triangle
```

Sử dụng Xpath để đọc dữ liệu XML trong Pandas

Bằng cách điều chỉnh tham số xpath trong hàm read_xml, ta có thể điều chỉnh các element nào sẽ được ghi vào DataFrame.

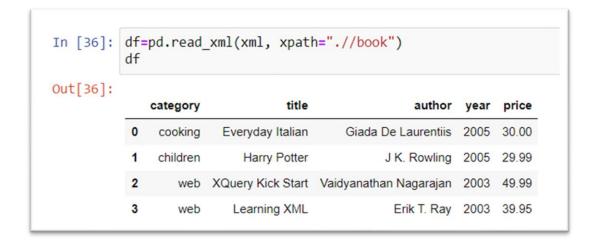
```
>>> xml = '''<?xml version='1.0' encoding='utf-8'?>
... <data>
    <row shape="square" degrees="360" sides="4.0"/>
    <row shape="circle" degrees="360"/>
      <row shape="triangle" degrees="180" sides="3.0"/>
... </data>'''
>>> df = pd.read xml(xml, xpath=".//row")
>>> df
     shape degrees sides
                     4.0
    square
                360
    circle
                360
                     NaN
 triangle
                       3.0
                180
```

Ta copy đoạn XML tại đây: XML and XPath (w3schools.com)

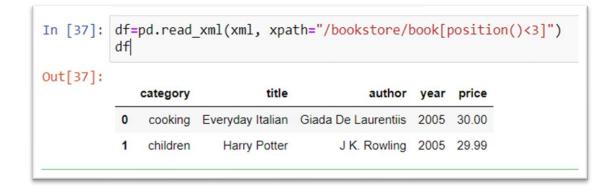
Lấy dữ liệu từ cuốn sách đầu tiên:



Lấy dữ liệu là tất cả các cuốn sách có trong xml:



Lấy dữ liệu là 2 cuốn sách đầu tiên:



Ghi dữ liệu từ DataFrame ra file XML

Ta dùng hàm to_xml() để ghi file xml từ DataFrame:

```
>>> df = pd.DataFrame({'shape': ['square', 'circle', 'triangle'],
                       'degrees': [360, 360, 180],
                       'sides': [4, np.nan, 3]})
>>> df.to_xml()
<?xml version='1.0' encoding='utf-8'?>
<data>
  <row>
    <index>0</index>
    <shape>square</shape>
    <degrees>360</degrees>
    <sides>4.0</sides>
  </row>
  <row>
    <index>1</index>
    <shape>circle</shape>
    <degrees>360</degrees>
    <sides/>
  </row>
  <row>
    <index>2</index>
    <shape>triangle</shape>
    <degrees>180</degrees>
    <sides>3.0</sides>
  </row>
</data>
```

Tham số attr_cols

Tham số attr_cols dùng để định nghĩa tên các cột sẽ lưu vào thuộc tính của các

element trong file xml.

```
>>> df.to_xml()
<?xml version='1.0' encoding='utf-8'?>
<data>
 <row>
   <index>0</index>
   <shape>square</shape>
   <degrees>360</degrees>
   <sides>4.0</sides>
 </row>
 <row>
   <index>1</index>
   <shape>circle</shape>
   <degrees>360</degrees>
   <sides/>
 </row>
 <row>
   <index>2</index>
   <shape>triangle</shape>
   <degrees>180</degrees>
   <sides>3.0</sides>
 </row>
</data>
```

